Tobigs 25 & 26th

Advanced Multimodal

Presenter : 25기 김태은

Contents

1. Recap & Bridge

2. MLLM Architecture · with Paper
   - LLaVA

3. Multimodal Reasoning · with Paper
   - Multimodal-CoT

4. Multimodal Generation · with Paper
   - Latent Diffusion

5. Transference & Wrap-up · with Paper
   - ImageBind

6. Quiz / Q&A / Assignment

Recap & Bridge

Recap & Bridge

Modality Gap : 정렬만으로는 부족하다

- **지난주 선택 과제 - Mind the Gap (arXiv:2203.02053)**
- CLIP으로 학습해도, 이미지 임베딩과 텍스트 임베딩은 같은 공간 안에서 서로 다른 영역(원뿔)에 분리되어 있음
- "같은 벡터 공간"이라는 형식은 같아도, 두 모달이 완전히 겹치지는 않는다 (week5 : 멀티모달 기초 강의 p.12)

12

Modality Representation & Encoder

Heterogeneity Gap(이질성 갭)

Modality	데이터 형태	특징
Image	2D spatial signal	spatial structure
Text	discrete tokens	symbolic / sequential
Audio	waveform / spectrogram	temporal signal
Video	spatial + temporal	high-dimensional sequence

- multimodal representation learning 연구에서는 multimodal data가 본질적으로 **heterogeneous** 하다.
- 서로 다른 modality의 representation을 어떻게 결합하고 관계를 학습할 것인지가 핵심적인 난제
- 이미지 representation은 visual information을 중심으로 학습된 공간이고, 텍스트 representation은 linguistic information을 중심으로 학습된 공간
- **Vector라는 형식은 같아도, Vector Space의 의미가 같다는 보장은 없다!**

→ 정렬(alignment)은 출발점

붙인 뒤 함께 추론하고 · 생성하고 · 더 많은 모달로 전이하는 것이 오늘의 주제

Recap & Bridge

Today's Journey

① ② ③ ④

붙인 뒤 함께 추론하고 · 생성하고 · 더 많은 모달로 전이하는 것이 오늘의 주제

① 붙이기 (Architecture)
LLM에 눈을 달다
논문 : LLaVA

② 추론 (Reasoning)
여러 단계로 생각하게 하다
논문 : Multimodal-CoT

③ 생성 (Generation)
텍스트로 이미지를 만들다
논문 : Latent Diffusion

④ 전이 (Transference)
두 모달을 넘어 여섯 모달로
논문 : ImageBind

MLLM Architecture with Paper

Multimodal Large Model : LLM에 눈을 달다

Q. Why MLLM?

기존 멀티모달의 한계

- CLIP · ViLT · LXMERT 등은 대부분 태스크 전용 (VQA용 / 검색용 / 캡셔닝용 따로)
- 정렬 · 매칭은 잘해도, 자유로운 대화 · 여러 단계 추론 능력은 없음
- 새 태스크 → 데이터 다시 모으고 다시 학습

LLM의 창발적 능력

- "이 지능이 언어에만 갇혀 있어야 할까? 눈을 달아주면 이미지도 대화 · 추론하지 않을까?"
- 하지만 LLM을 이미지까지 넣어 처음부터 다시 학습하는 건 비용상 불가능

→ 발상 전환 : "잘 학습된 CLIP과 LLM을 새로 만들지 말고, 연결(connect)만 하자"

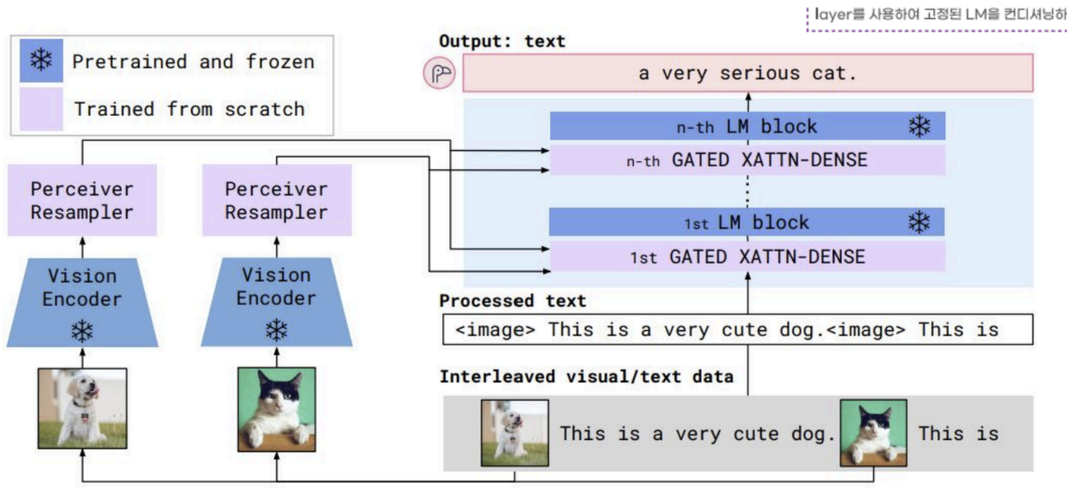
소개할 아키텍처: 무거운 두 모델은 고정(frozen), 가벼운 연결자만 학습 → 적은 비용으로 LLM 능력을 시각으로 확장

MLLM Architecture

지난주 복습 : Flamingo & BLIP-2

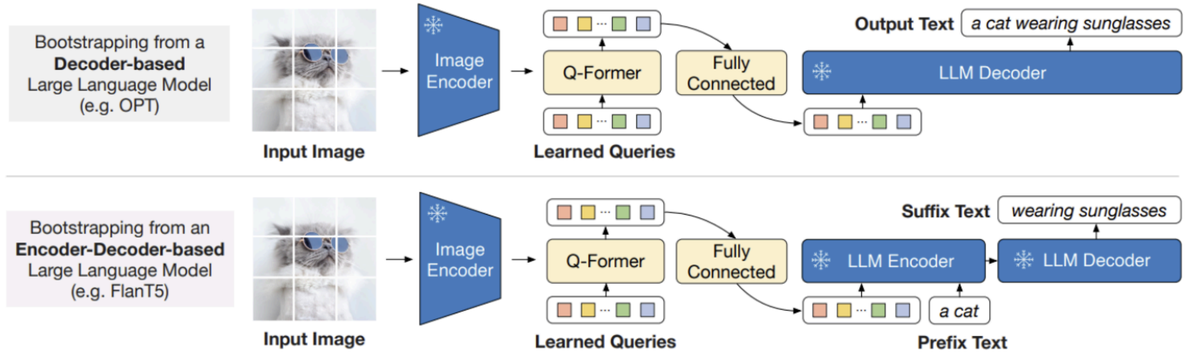
- 지난주에 이미 두 가지 연결(connector) 방식을 배웠다

Flamingo



고정된 LLM 레이어 사이에
Gated Cross-Attention 삽입 → 시각 정보를 LLM이 참조

BLIP-2



Q-Former (learnable query)가
이미지→텍스트 필요한 정보만 압축 → 압축된 표현을 LLM에 전달

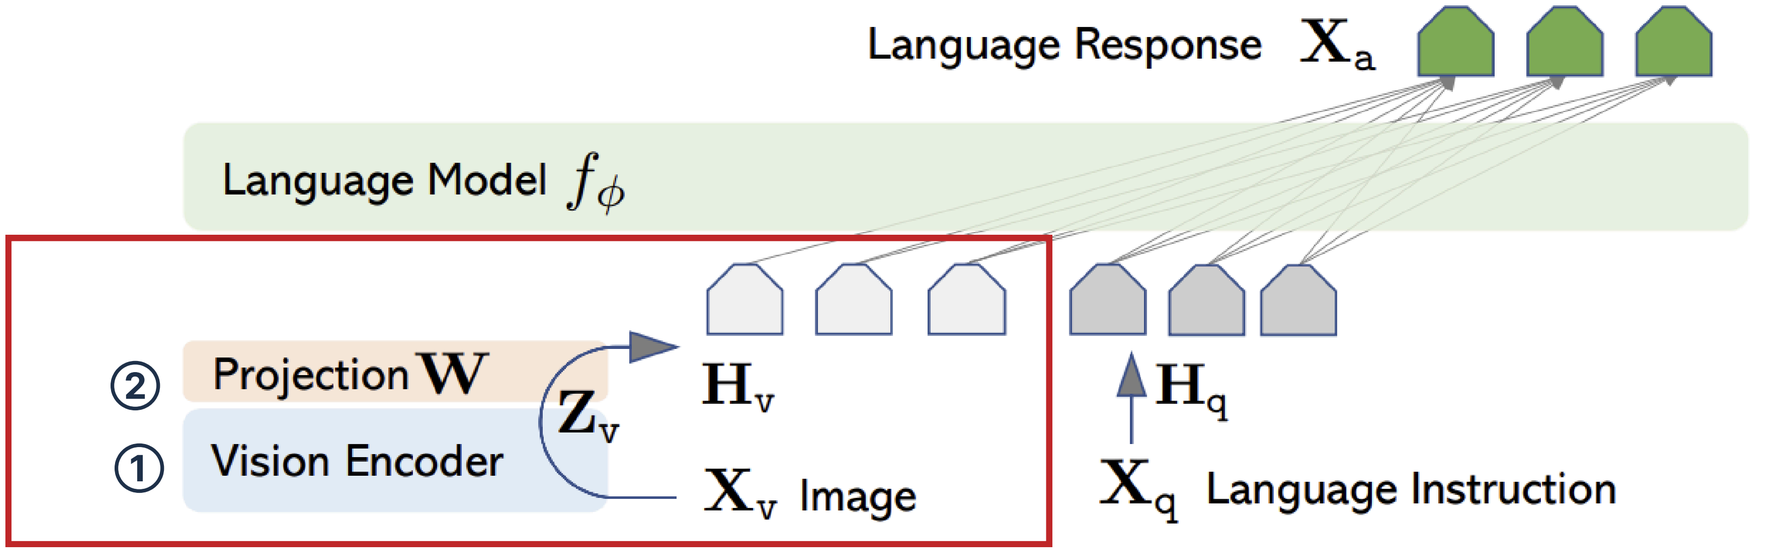
공통점 : 강력한 사전학습 Vision Encoder + 사전학습 LLM 을 **연결(connector)**하는 것이 핵심

Q. 연결자를 꼭 이렇게 복잡하게 만들어야 할까?

MLLM Architecture

LLaVA : Vision Encoder + Projection + LLM

LLaVA = Large Language and Vision Assistant



이미지 경로

Figure 1: LLaVA network architecture.

① **Vision Encoder**
CLIP ViT-L/14 **(freeze)**

이미지를 시각 특징으로 인코딩
Zv : 아직 LLM이 못 알아듣는 비전 언어

학습 가능한 선형 층 1개
② **Projection W**

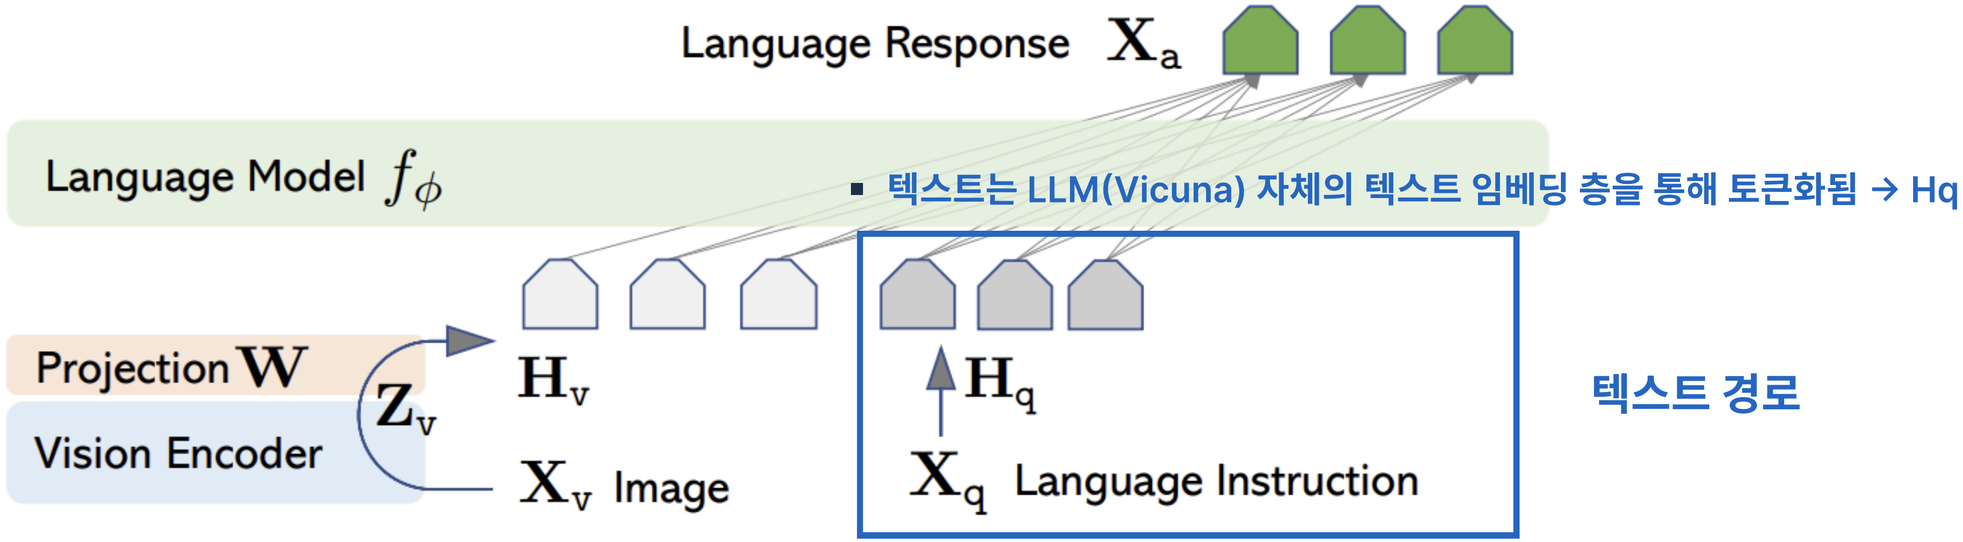
Zv를 LLM의 단어 임베딩 공간으로 변환

LLM이 단어처럼 취급할 수 있는 형태
③ **Hv** 이미지 토큰

MLLM Architecture

LLaVA : Vision Encoder + Projection + LLM

LLaVA = Large Language and Vision Assistant



- 텍스트는 LLM(Vicuna) 자체의 텍스트 임베딩 층을 통해 토큰화됨 → Hq

Figure 1: LLaVA network architecture.

Q. W가 이미지에만 붙는 이유?

- 이미지는 LLM이 해석 못하는 공간(=이미지 공간)에서 오니 번역이 필요하고, 텍스트는 이미 LLM의 공간에 있으니 번역이 불필요하기 때문

MLLM Architecture

LLaVA : Vision Encoder + Projection + LLM

LLaVA = Large Language and Vision Assistant

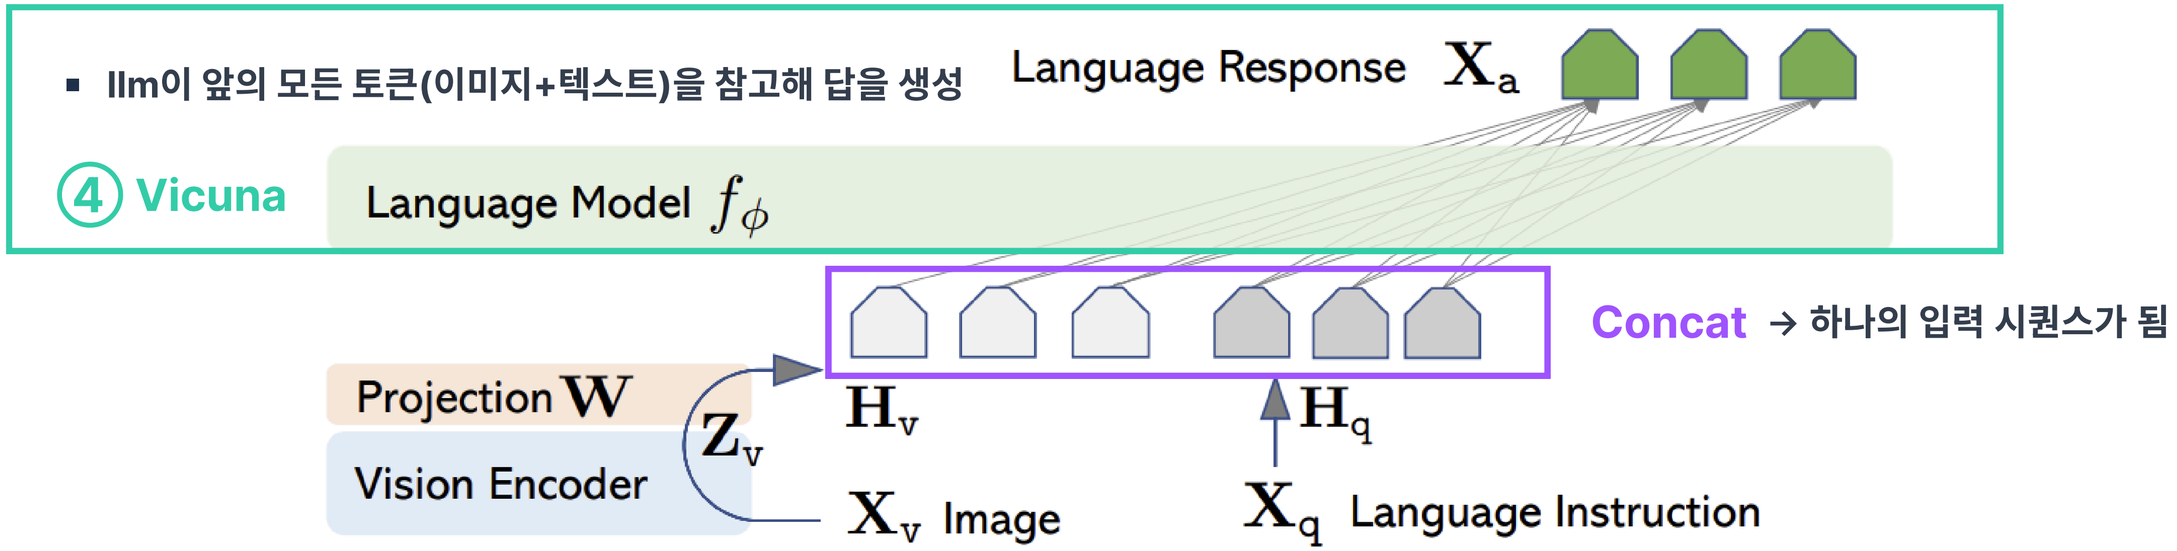


Figure 1: LLaVA network architecture.

Key

연결자는 Projection W 하나뿐

- Cross-Attention도, Q-Former도 아닌 단순 선형 사영으로 시각 토큰을 LLM 입력에 나란히 넣음
- "차원을 맞춰 같은 공간에 올려놓는" 역할
- 기초에서 배운 Early Fusion – Type II 의 실제 구현

MLLM Architecture

LLaVA : 실제 코드로 보는 "단순함"

Projection W : Connector = 선형/MLP layer

```
def build_vision_projector(config, delay_load=False, **kwargs):
    projector_type = getattr(config, 'mm_projector_type', 'linear')

    if projector_type == 'linear':
        return nn.Linear(config.mm_hidden_size, config.hidden_size)

    mlp_gelu_match = re.match(r'^mlp(\d+)x_gelu$', projector_type)
    if mlp_gelu_match:
        mlp_depth = int(mlp_gelu_match.group(1))
        modules = [nn.Linear(config.mm_hidden_size, config.hidden_size)]
        for _ in range(1, mlp_depth):
            modules.append(nn.GELU())
            modules.append(nn.Linear(config.hidden_size, config.hidden_size))
        return nn.Sequential(*modules)
```

초기에는 선형 층 1개였음

LLaVA-1.5는 2층 MLP
- Linear → GELU → Linear

이미지 인코더 : 이미지 토큰으로 만드는 과정

```
def encode_images(self, images):
    image_features = self.get_model().get_vision_tower()(images)
    image_features = self.get_model().mm_projector(image_features)
    return image_features
```

고정된 CLIP ViT 통과 : X_v → Z_v

Projection W : Z_v → W → H_v

MLLM Architecture

LLaVA : Results & Why It Matters

- **성능 (논문 보고 수치)**

GPT-4 대비 상대 85.1%
합성 멀티모달 instruction 데이터

ScienceQA 92.53%
fine-tune 시, 당시 SOTA

- **시사점 : 왜 단순한 선형 층이 통했나?**
  - 강력한 사전학습 인코더 + LLM이 이미 좋은 표현을 갖고 있음
  - 필요한 것은 둘을 잇는 정렬 + 지시 데이터 뿐

→ 단순함 = 확장성 · 재현성의 이점 → 이후 대부분의 MLLM이 이 방식으로 수렴

- 참고 : Chameleon (Meta, 2024) : 이미지를 토큰으로 변환해 텍스트 토큰과 함께 처음부터 하나의 Transformer로 학습 (native early-fusion)
  - 이해(understanding) + 생성(generation)을 한 모델에서 수행 (Part 3에서 다시 등장)

Multimodal Reasoning with Paper

붙인 다음, 여러 단계로 생각하게 하기

Multimodal Reasoning

What is Multimodal Reasoning?

- **Reasoning: 멀티모달의 증거로부터 지식을 여러 단계의 추론(inferential steps)으로 조합**
- **언어 모델에서는 이미 Chain-of-Thought (CoT) 가 효과적**

  ex. "차근차근 생각해보자" → 중간 추론 과정을 생성한 뒤 답

Q. 이미지가 낀 문제에서도 CoT가 그대로 통할까?

Multimodal Reasoning

문제 : Hallucinated Rationale

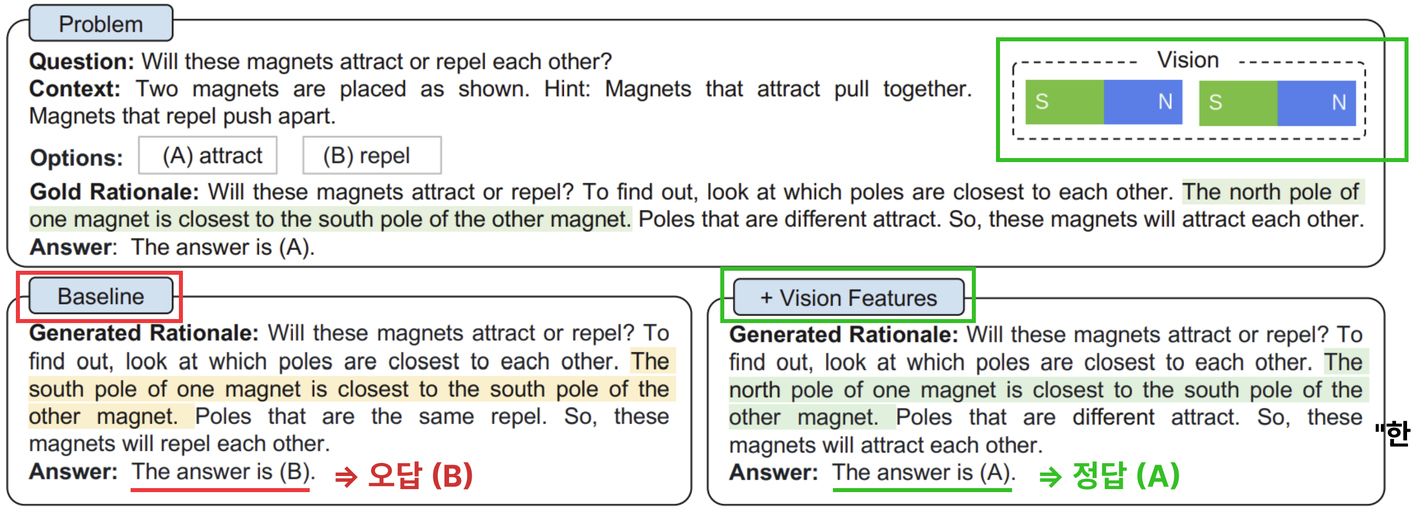
- 언어 CoT를 멀티모달에 그냥 적용하면?
- 특히, 10억(1B) 파라미터 미만의 작은 모델은 환각된(hallucinated) 근거를 생성

vision 없는 경우

↓

"한 자석의 S극이 다른 자석의 S극과 가장 가깝다"

⇒ 잘못된 근거 생성



+ vision feature

↓

"한 자석의 N극이 다른 자석의 S극과 가장 가깝다"

⇒ 올바른 근거 생성

Figure 2: Example of the two-stage framework without vision features (baseline) and with vision features (ours) for generating rationales and predicting answers. The upper part presents the problem details with a gold rationale, and the lower part shows the outputs of the baseline and our method incorporated with vision features. We observe that the baseline fails to predict the right answer due to the misleading by hallucinated rationales. More examples are shown in Appendix A.1.

baseline은 이미지를 제대로 반영하지 못하는 잘못된 추론 chain → 오답으로 이어짐

Multimodal Reasoning

Multimodal-CoT : Two-Stage Framework

핵심 : 두 단계 모두에 vision feature를 주입
이미지가 있어야 근거 품질이 오르고, 좋은 근거가 정답률을 올린다

- Multimodal-CoT : 근거 생성과 정답 추론을 2단계로 분리

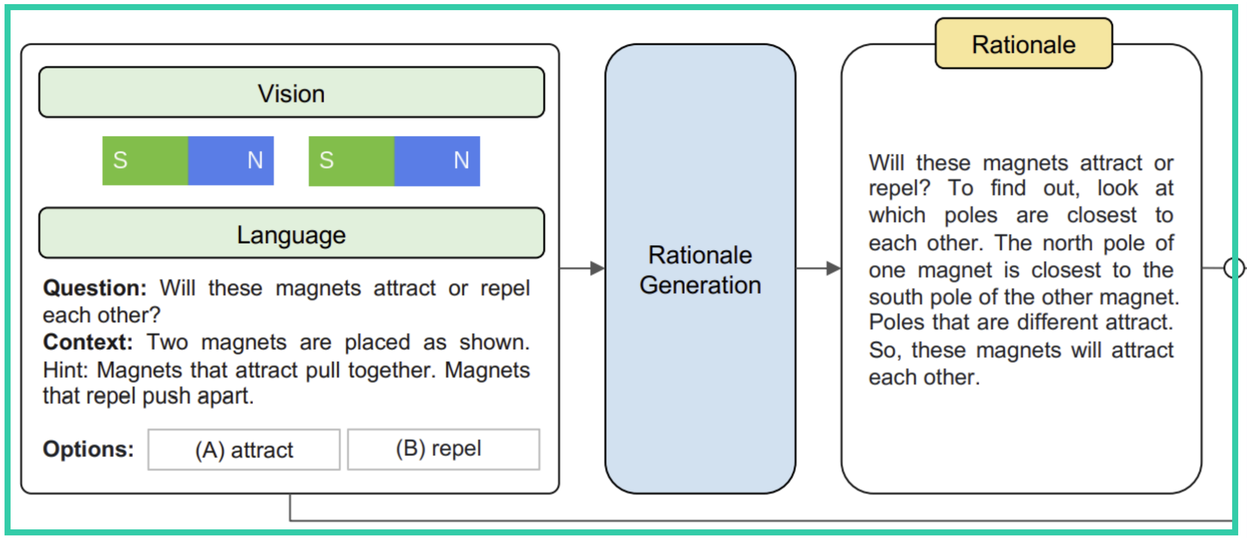
$$R = F(X)$$

입력 : 질문 + 선택지 + 이미지

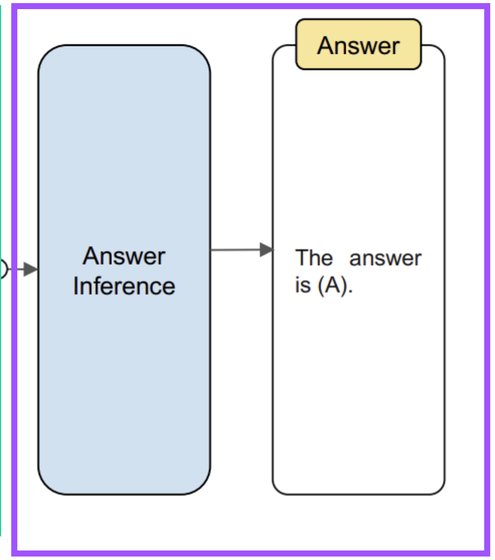
$$X = \{X^1_{\text{language}}, X_{\text{vision}}\}$$

Stage 1 _ Rationale Generation

출력 : 근거(rationale) 텍스트



Stage 2 _ Answer Inference



출력 : 정답

$$A = F(X')$$

입력 : 질문+선택지+이미지+근거

$$X^2_{\text{language}} = X^1_{\text{language}} \circ R$$

→ **concatenation.** 원래 질문 뒤에 생성된 근거를 이어붙임

Multimodal Reasoning

Multimodal-CoT : Two-Stage Framework

심화 : 모델은 이미지와 텍스트를 어떻게 섞나 (수식으로 알아보기)

① Encoding → ② Interaction → ③ Gated Fusion → ④ Decoding

① Encoding : 두 모달을 각각 인코딩

$$H_{\text{language}} = \text{LanguageEncoder}(X_{\text{language}}),$$ → 텍스트 인코더(Transformer)

$$H_{\text{vision}} = W_h \cdot \text{VisionExtractor}(X_{\text{vision}}),$$ → ViT 인코더에 선형 사영 W_h 적용 → 텍스트와 차원 맞춤

② Interaction : 텍스트가 이미지를 참조 = cross attention (지난주 강의)

$$H^{\text{attn}}_{\text{vision}} = \text{Softmax}(\frac{QK^\top}{\sqrt{d_k}})V,$$

- Q = H_language
- K = V = H_vision (single-head)

→ 해석 : 각 텍스트 토큰이 이미지의 모든 패치를 훑어보고, 자신과 관련 깊은 패치일수록 더 많이 참고해서 시각 정보를 가져온다

③ Gated Fusion : 이미지 정보를 얼마나 반영할지 게이트 λ로 조절 (지난주 강의 Gated Fusion)

$$\lambda = \text{Sigmoid}(W_l H_{\text{language}} + W_v H^{\text{attn}}_{\text{vision}}),$$

$$H_{\text{fuse}} = (1-\lambda) \cdot H_{\text{language}} + \lambda \cdot H^{\text{attn}}_{\text{vision}},$$

이 논문의 핵심 계산은
지난주에 배운 Cross-Attention과 Gated Fusion

④ Decoding : H_fuse 를 Transformer decoder에 넣어 → 타겟 Y(근거/정답) 생성

Finally, the fused output H_{fuse} is fed into the Transformer decoder to predict the target Y.

Multimodal Reasoning

Multimodal-CoT : Results

1B 미만 모델이 ScienceQA에서 당시 GPT-3.5를 약 16%p 상회

75.17% → 91.68%

분석상 이점

- 환각(hallucination) 감소
- 수렴 속도 향상 (초반부터 더 높은 정확도)

메시지 : 모델을 키우는 대신, 추론을 구조로 유도해 작은 모델로도 강한 추론 달성

(참고) 관련 연구 소개

- POPE (arXiv:2305.10355) : MLLM의 환각(없는 물체를 있다고 함)을 Yes/No로 측정하는 벤치마크
- Visual CoT (Shao et al., NeurIPS 2024, arXiv:2403.16999) : 거대 MLLM이 추론에 필요한 이미지 영역을 스스로 찾아 집중 추론
- "Thinking with Images" (예: OpenAI o3 계열) : 이미지를 crop·zoom 하는 시각적 조작 자체를 추론에 포함

Multimodal Generation with Paper

텍스트로 이미지를 만들다

Multimodal Generation

Generation & Diffusion 직관

⭐ 오늘은 Text-to-Image 에 집중

- 멀티모달 Generation (CMU 분류) : 번역(캡셔닝, Text→Image) · 요약 · 창작

Diffusion 직관 이해

① 학습 (Forward + Denoise)

- 이미지에 노이즈를 조금씩 더한 뒤
- 노이즈를 한 스텝씩 지우는(denoise) 법을 학습

② 생성 (Reverse)

- 순수 노이즈에서 시작
- 반복적으로 지워가며 이미지 완성

Diffusion 한 줄 수식

$$L_{DM} = \mathbb{E}_{x,\epsilon\sim\mathcal{N}(0,1),t}\left[\|\epsilon - \epsilon_\theta(x_t, t)\|_2^2\right], \qquad (1)$$

의미 : 모델 ε_θ가 노이즈 낀 이미지 x_t와 그 단계 t를 입력받아 → 그때 더해진 노이즈 ε를 맞히도록 학습 → 노이즈를 알면 지울 수 있음

Multimodal Generation

Latent Diffusion : LDM 전체 flow

문제 : 픽셀 공간에서 직접 diffusion → 막대한 계산·GPU 비용(당시 선도 모델 150~1000 V100 GPU-day)

LDM (Rombach et al., 2022) 핵심 → 압축 단계와 생성 단계를 명시적으로 분리

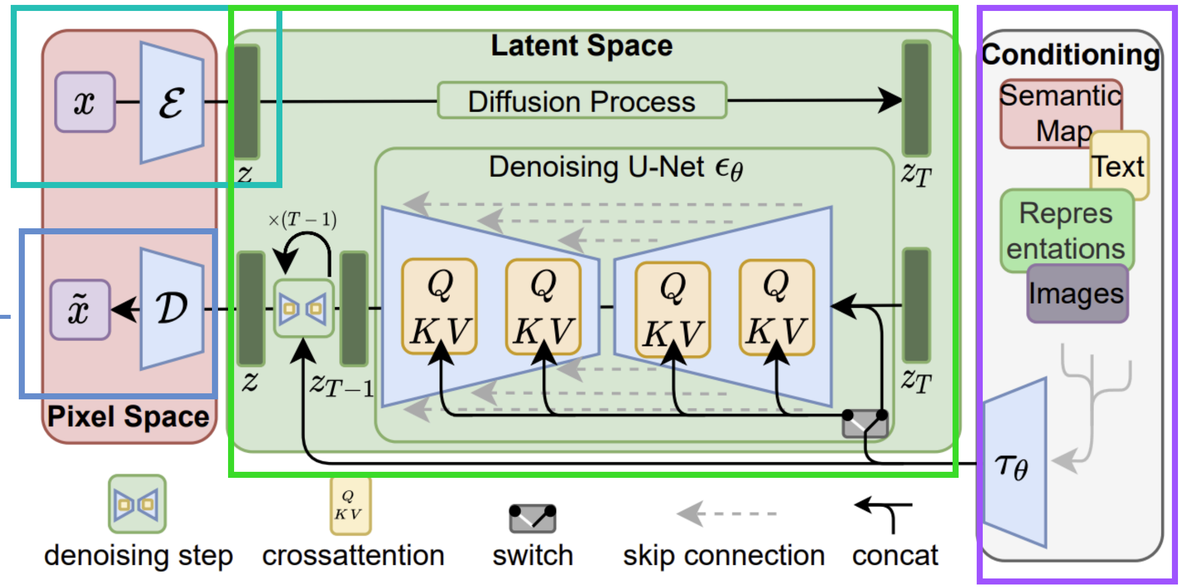
그림의 z_T → z_{T-1} → … : 노이즈를 한 스텝씩 지우는 과정 (범례의 denoising step)

② 생성 : 압축된 공간(잠재 공간)에서 Denoising U-Net이 노이즈를 반복 제거 → 깨끗한 z̃

- 여기서만 diffusion이 일어남 (픽셀이 아니라 z 위에서)
- 이미지의 의미·구성을 학습하는 데 집중 (semantic compression)

① Perceptual compression : 별도로 사전 학습된 Autoencoder

- **이미지 x → 인코더 $\mathcal{E}$ → 잠재 z**
- 사람 눈에 안 보이는 고주파 디테일을 걷어냄 (perceptual compression)



③ 복원

z̃ → 디코더 $\mathcal{D}$ → 최종 이미지 x̃

- 생성이 다 끝난 z를 다시 이미지로 되돌림

Conditioning

텍스트 등 y → τθ → ②단계의 매 denoise 스텝마다 참조

"크게 줄여서(①) → 그 안에서 그리고(②) → 다시 키운다(③), 그리는 내내 주문서(조건)를 본다"

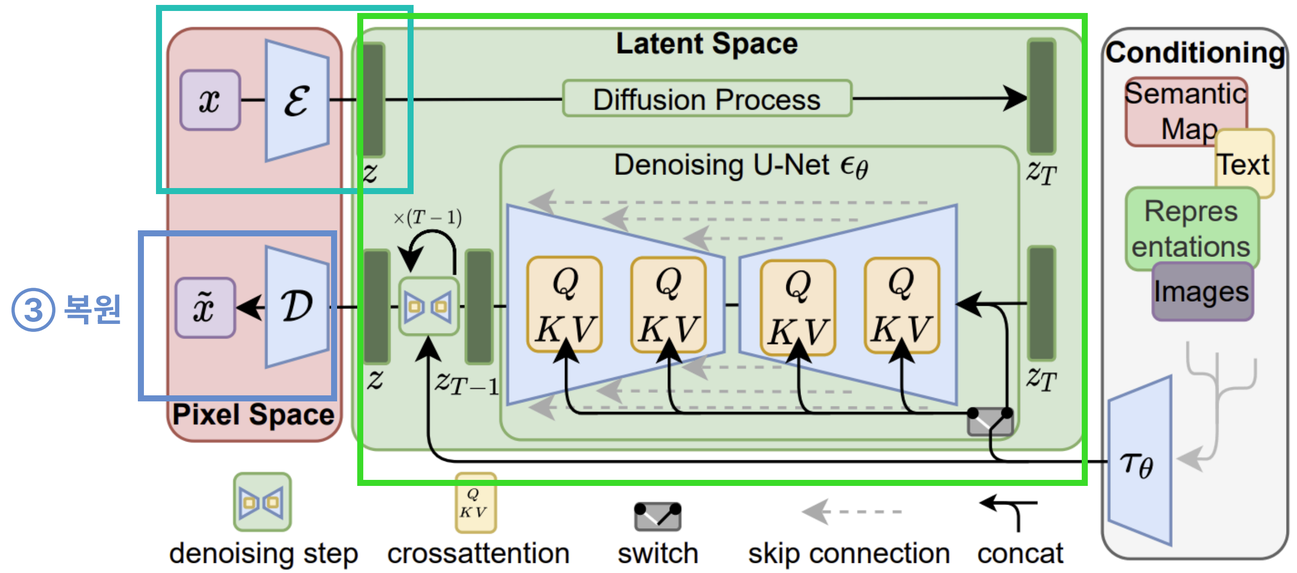
실제 이미지를 '생성'하는 엔진

Multimodal Generation

Latent Diffusion : LDM 전체 flow

① Perceptual compression

② 생성



① Perceptual compression ② 생성 ③ 복원

"크게 줄여서(①) → 그 안에서 그리고(②) → 다시 키운다(③), 그리는 내내 주문서(조건)를 본다"

실제 이미지를 '생성'하는 엔진

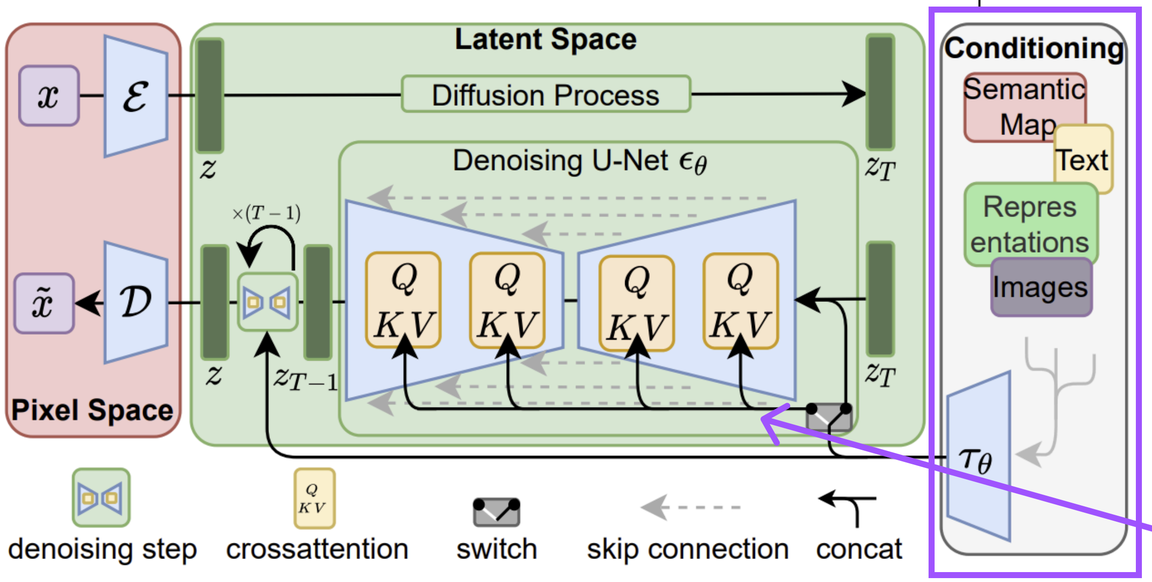
latent가 효율적인 이유

- **의미에만 집중** : autoencoder가 지각적으로 안 중요한 걸 미리 제거 → diffusion은 의미에만 집중 → 화질 유지·비용 급감
- **범용 autoencoder** : 한 번 학습해 여러 생성 모델이 재사용 (Stable Diffusion 생태계의 기반)

Multimodal Generation

조건 주입 : Cross-Attention

Q. "고양이 그림"이라는 텍스트 조건(y)을 어떻게 넣을까?



확장성 (참고) : 조건 y는 텍스트만이 아니다

- Text → Text-to-Image ("고양이 그림")
- Semantic Map (영역별 라벨 지도) → 레이아웃대로 이미지 생성
- Images → 저해상도→고해상도(super-resolution), 밑그림→완성 등 image-to-image
- Representations (클래스 라벨·특징 벡터 등) → 클래스 조건 생성 등

⭐ 핵심 : 조건 벡터로 바꾸는 τθ만 갈아끼우면, 같은 U-Net + cross-attention 구조로 이 모든 조건부 생성 가능
→ LDM의 범용성

1. τθ(도메인 인코더) 필요

텍스트와 이미지는 형태가 완전히 다르기 때문(= Heterogeneity Gap)

- U-Net은 글자를 못 알아들음 → τθ가 조건 y를 U-Net이 참조할 수 있는 벡터 τθ(y)로 "번역" (텍스트일 땐 Transformer)

번역된 결과 τθ(y) 전달

$$Q = W_Q^{(i)} \cdot \varphi_i(z_t),\ K = W_K^{(i)} \cdot \tau_\theta(y),\ V = W_V^{(i)} \cdot \tau_\theta(y).$$

2. τθ(y)를 U-Net에 Cross-Attention으로 삽입

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right) \cdot V$$

→ Why cross-attention?

- 길이 다른 두 시퀀스(이미지 위치 N개 ↔ 단어 M개)를 유연하게 연결, 다양한 모달에 효과적

→ 왜 조건 τθ(y)을 딱 한 번이 아니라, 매 denoise 스텝마다 cross-attention으로 참조하느냐?

- diffusion 생성은 한 번에 안 끝남 → 노이즈를 여러 스텝에 걸쳐 조금씩 지움
- 조건을 처음 한 번만 주면 뒤쪽 스텝이 조건을 잊고 벗어날 수 있음
- 매 스텝 참조 → 단계에 맞게 조건이 계속 반영

학습 Loss (참고) $L_{LDM} := \mathbb{E}_{\mathcal{E}(x),y,\epsilon\sim\mathcal{N}(0,1),t}\left[\|\epsilon - \epsilon_\theta(z_t, t, \tau_\theta(y))\|_2^2\right]$

diffusion의 원문 식(1)과 같은 "노이즈 예측 오차"에 조건 τθ(y)만 추가
→ τθ와 U-Net을 하나의 Loss로 함께(jointly) 학습

$$L_{DM} = \mathbb{E}_{x,\epsilon\sim\mathcal{N}(0,1),t}\left[\|\epsilon - \epsilon_\theta(x_t, t)\|_2^2\right], \qquad (1)$$

Multimodal Generation

조건 주입 : Cross-Attention

Q. "고양이 그림"이라는 텍스트 조건(y)을 어떻게 넣을까?



A. Cross-Attention이 멀티모달 생성 모델의 조종간
=텍스트 조건이 이미지 생성을 제어하는 통로

1. τθ(도메인 인코더) 필요

텍스트와 이미지는 형태가 완전히 다르기 때문(= Heterogeneity Gap)

- U-Net은 글자를 못 알아들음 → τθ가 조건 y를 U-Net이 참조할 수 있는 벡터 τθ(y)로 "번역" (텍스트일 땐 Transformer)

번역된 조건 $\tau_\theta(y)$ 전달

$$Q = W_Q^{(i)} \cdot \varphi_i(z_t),\ K = W_K^{(i)} \cdot \tau_\theta(y),\ V = W_V^{(i)} \cdot \tau_\theta(y).$$

2. τθ(y)를 U-Net에 Cross-Attention으로 삽입

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right) \cdot V$$

→ Why cross-attention?

- 길이 다른 두 시퀀스(이미지 위치 N개 ↔ 단어 M개)를 유연하게 연결, 다양한 모달에 효과적

→ 왜 조건 τθ(y)을 딱 한 번이 아니라, 매 denoise 스텝마다 cross-attention으로 참조하느냐?

- diffusion 생성은 한 번에 안 끝남 → 노이즈를 여러 스텝에 걸쳐 조금씩 지움
- 조건을 처음 한 번만 주면 뒤쪽 스텝이 조건을 잊고 벗어날 수 있음
- 매 스텝 참조 → 단계에 맞게 조건이 계속 반영

학습 Loss (참고) $L_{LDM} := \mathbb{E}_{\mathcal{E}(x),y,\epsilon\sim\mathcal{N}(0,1),t}\left[\|\epsilon - \epsilon_\theta(z_t, t, \tau_\theta(y))\|_2^2\right]$

diffusion의 원문 식(1)과 같은 "노이즈 예측 오차"에 조건 τθ(y)만 추가

$$L_{DM} = \mathbb{E}_{x,\epsilon\sim\mathcal{N}(0,1),t}\left[\|\epsilon - \epsilon_\theta(x_t, t)\|_2^2\right], \qquad (1)$$

Multimodal Generation

(참고) 이해와 생성을 한 모델로

- 지금까지 : 이해 모델(LLaVA)과 생성 모델(LDM)은 별개
- **최근 흐름 : 하나의 모델에서 이해 + 생성**
  - Chameleon (Part 1 재등장) : 이미지·텍스트를 모두 토큰으로 → 하나의 Transformer로 이해와 생성

"MLLM이 그림도 그리게 하려면?" 이라는 질문의 최신 방향

Transference & Wrap-up with Paper

두 모달을 넘어, 여섯 모달로

Transference

ImageBind : One Embedding Space

- CLIP 복습 : (이미지, 텍스트) 2개 모달을 대조학습으로 정렬

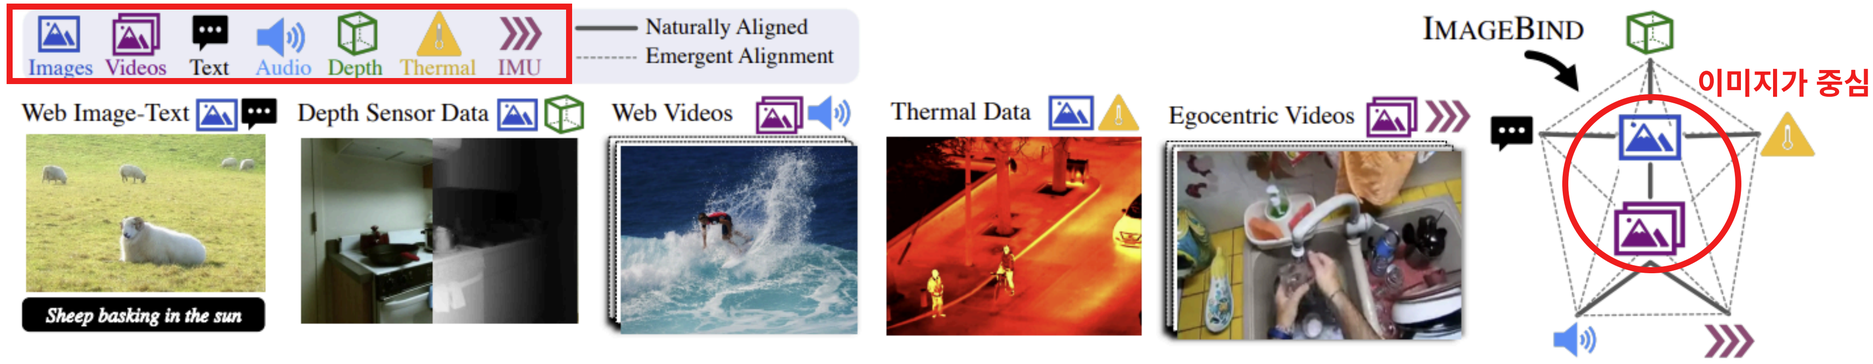
Q. 오디오·깊이·열화상·IMU까지 넣으려면 모든 쌍의 데이터가 필요할까? (6모달 → 15쌍)

→ ImageBind (Girdhar et al., CVPR 2023)

⭐ **핵심 통찰 : 이미지를 허브(hub)로, "이미지와 짝지어진 데이터"만으로 정렬**

- 논문 내용: align each modality’s embedding to image embeddings
- 각 모달을 이미지(또는 비디오)와만 짝지어 학습: 짝의 한쪽은 항상 이미지 = 허브 (모달끼리 직접 짝짓지 않음)
- 모두 자연히 함께 존재하는(naturally paired) 데이터 → 별도 라벨링 수고 없이 수집 (동영상엔 소리+화면, 1인칭 영상엔 IMU+화면이 원래 함께 있음)

6개 모달 : 이미지 · 텍스트 · 오디오 · 깊이(depth) · 열화상(thermal) · IMU



Transference

ImageBind : 어떻게 학습하고 구현하나

→ ImageBind (Girdhar et al., CVPR 2023)

⭐ [학습] 무엇을, 어떤 손실로 정렬할까?

- **각 (이미지, 모달) 쌍을 InfoNCE loss로 정렬** → 지난주 CLIP에서 배운 대조학습(Contrastive Learning)
- 짝(positive)은 가깝게, 배치 내 나머지(negative)는 멀게
- CLIP과 차이는 '대상' : CLIP은 텍스트 하나 vs ImageBind는 이미지를 여러 모달에 허브로 반복 적용

⭐ [구현] 그 학습을 어떤 구조로 실현할까?

- 정렬이 성립하려면 모든 모달이 같은 형식의 임베딩으로 나와야 함
- 모든 모달에 Transformer(ViT류) 인코더 + 모달별 projection head → 공통 d차원 임베딩으로 통일
  - 이미지·텍스트 인코더 = OpenCLIP으로 사전학습 후 고정(frozen) → 이미 정렬된 (이미지, 텍스트) 공간을 허브의 기준점으로 삼음
  - 나머지(오디오·깊이·열·IMU) 인코더만 학습 → 각자를 이 고정된 이미지 공간에 맞춰 붙임

⇒ 결과: CLIP이 가진 언어-이미지 지식이 새 모달로 전이되면서, 여섯 모달이 하나의 공통 공간에 모임

Transference

ImageBind : Emergent Alignment

Emergent Alignment (창발적 정렬)

- (이미지- 오디오)와 (이미지-텍스트)만 학습했는데, 한 번도 같이 본 적 없는 (오디오, 텍스트)도 정렬됨

  → **학습하지 않은 조합의 cross-modal retrieval이 zero-shot으로 가능**

응용 (out-of-the-box)

- 임베딩 산술 조합 (예: 이미지 + 오디오로 검색) → Figure 4
- Audio-to-Image 생성 (오디오 임베딩을 CLIP 텍스트용 DALL·E-2 디코더에 입력)
  ex) 개 짖는 소리를 넣으면 개 사진을 찾아옴

"이미지 인코더가 강할수록 창발 성능이 좋아짐 → 허브 품질이 전체를 좌우"

- 서로 다른 모달의 임베딩을 더하면 그 의미들이 자연스럽게 결합됨

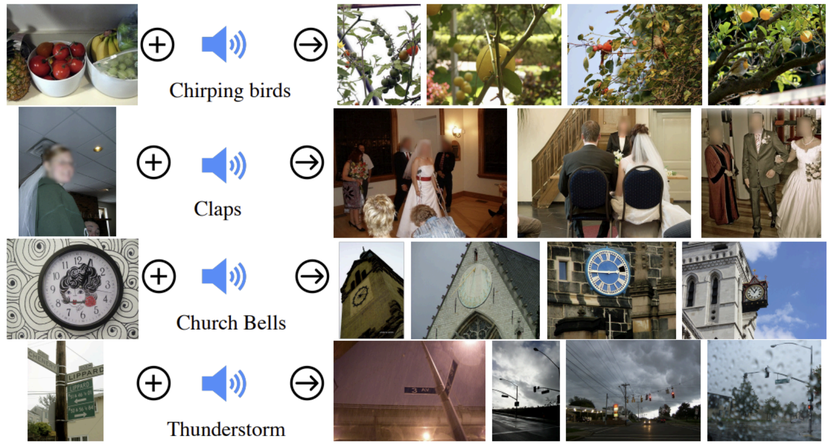


Figure 4. Embedding space arithmetic where we add image and audio embeddings, and use them for image retrieval. The composed embeddings naturally capture semantics from different modalities. Embeddings from an image of fruits + the sound of birds retrieves images of birds surrounded by fruits.

Transference

ImageBind : 코드로 보는 One Embedding Space

imagebind_demo.py

```python
from imagebind import data
from imagebind.models import imagebind_model
from imagebind.models.imagebind_model import ModalityType

# 사전학습된 ImageBind 모델 로드
model = imagebind_model.imagebind_huge(pretrained=True).eval().to(device)

# 1) 서로 다른 모달을 각각 로드 (텍스트 · 이미지 · 오디오)
inputs = {
    ModalityType.TEXT:   data.load_and_transform_text(text_list, device),
    ModalityType.VISION: data.load_and_transform_vision_data(image_paths, device),
    ModalityType.AUDIO:  data.load_and_transform_audio_data(audio_paths, device),
}

# 2) 한 번의 forward로 모든 모달을 같은 임베딩 공간으로
with torch.no_grad():
    embeddings = model(inputs)

# 3) 서로 다른 모달을 그냥 내적(@)으로 비교 - 같은 공간이라 가능!
vision_x_text = torch.softmax(embeddings[VISION] @ embeddings[TEXT].T, dim=-1)
audio_x_text  = torch.softmax(embeddings[AUDIO]  @ embeddings[TEXT].T, dim=-1)
```

핵심 : 텍스트·이미지·오디오를 각각 넣었는데, 결과를 그냥 내적(@)으로 비교

→ 같은 공간에 있다는 증거

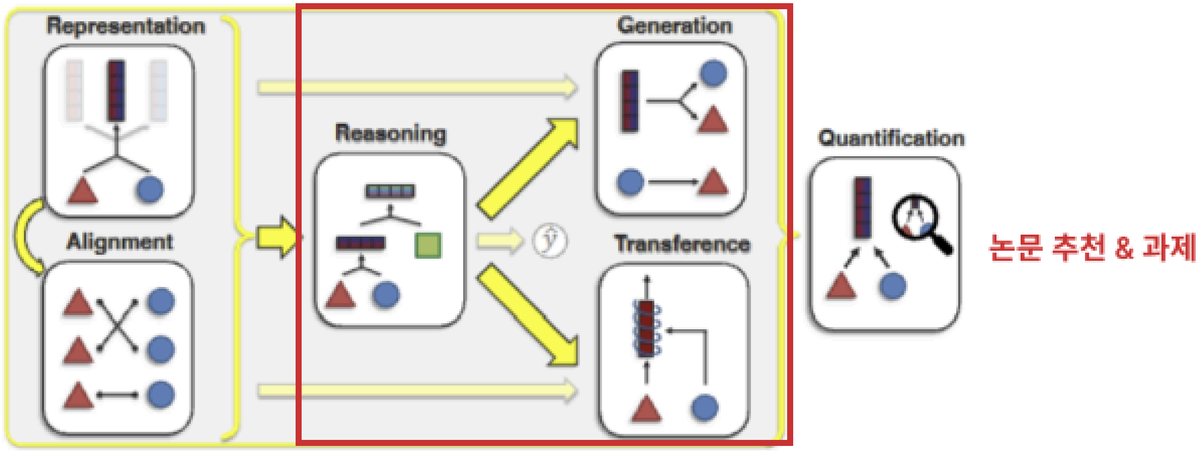
Wrap-up

6대 과제로 돌아보기

Architecture/Fusion	LLaVA	projection으로 LLM에 눈을 달다
Reasoning	Multimodal-CoT	2단계로 추론을 구조화

What is Multimodal AI ?

Multimodal AI의 핵심 과제



논문 추천 & 과제

오늘 다룬 부분

Generation	Latent Diffusion	잠재 공간 + Cross-Attention 조건
Transference	ImageBind	이미지 허브로 6개 모달 정렬

관통 메시지

"지난주에 배운 인코더 · CLIP · Cross-Attention이 오늘 모든 모델의 부품"

Quiz

[객관식] 다음 중 틀린 것을 하나 고르시오.

① LLaVA는 Vision Encoder와 LLM을 연결할 때, 복잡한 구조 대신 선형 사영(projection) 을 사용한다.

② Multimodal-CoT은 근거 생성과 정답 추론을 2단계로 나누고, 두 단계 모두에 이미지 정보를 넣는다.

③ Latent Diffusion은 계산 비용을 줄이기 위해 압축된 잠재(latent) 공간에서 diffusion을 수행한다.

④ Latent Diffusion에서 Cross-Attention은 텍스트 조건을 이미지 생성에 넣는 역할을 한다.

⑤ ImageBind는 6개 모달을 하나의 공간에 정렬하기 위해, 모든 모달 쌍(15개)을 전부 짝지어 학습해야 한다.

[주관식] Latent Diffusion에서 Cross-Attention은 (1) 어떤 역할을 하는가?
(2) 만약 Cross-Attention으로 텍스트 조건을 넣지 않는다면 이미지 생성 결과는 어떻게 될지 본인의 말로 서술하시오.

Reference

중심 논문 (Part별)

- LLaVA — Visual Instruction Tuning (arXiv:2304.08485)
- Multimodal-CoT (arXiv:2302.00923)
- Latent Diffusion Models (arXiv:2112.10752)
- ImageBind (arXiv:2305.05665)

참고

- Mind the Gap (arXiv:2203.02053)
- Chameleon (arXiv:2405.09818)
- POPE (arXiv:2305.10355)
- Foundations & Trends in Multimodal ML (arXiv:2209.03430)

강의

CMU 11-777 Multimodal Machine Learning (Morency)